یادگیری ماشین برای پردازش سیگنال

تمرین اول

راهنمای انجام و ارائه پاسخ

ابتدا بخش صفر نوت‌بوک را برای اجرای تنظیمات و ابزارهای مشترک اجرا کنید. در سؤال اول، توابع مشخص‌شده با `TODO-FUNCTION` را کامل کرده و آزمایش‌های آماده را اجرا کنید. در سؤال‌های دوم و سوم، پیاده‌سازی بخش‌های مشخص‌شده بر عهده شماست. در سؤال چهارم، کد تولید داده و بخش‌های مربوط به محاسبات عددی، initialization، حلقه EM و اجرای مدل با چند مقداردهی اولیه آماده‌اند. شما باید E-step و M-step را پیاده‌سازی کرده و بخش‌های مقایسه و ارزیابی مدل‌ها را مطابق دستور نوت‌بوک تکمیل کنید..

استفاده از ابزارهای جبر خطی، بهینه‌سازی عددی، پیش‌پردازش و محاسبه معیارها مجاز است. استفاده از برازشگر آماده فقط برای LASSO مجاز بوده و برای LDA، QDA، رگرسیون لجستیک و GMM مجاز نیست. همه پاسخ‌ها، نمودارها و تحلیل‌ها را در نوت‌بوک ارائه کنید (گزارش جداگانه لازم نیست).

پیش از تحویل، با اجرای Restart و Run All از اجرای ترتیبی و بازتولیدپذیری نتایج اطمینان حاصل کنید.

1 استنباط آماری از سیگنال‌های شبیه‌سازی‌شده

هدف، برآورد دامنه یک پالس گذرا و بررسی اثر مدل نویز، prior و تابع زیان است. شکل و محل شروع پالس معلوم‌اند و بیشینه نمونه‌برداری‌شده الگو برابر یک است. جزئیات ورودی و خروجی توابع در نوت‌بوک آمده است.

1.1 برآورد دامنه و عملکرد آماری

برای مدل

$$\mathbf{y} = a\mathbf{s} + \mathbf{n}, \qquad \mathbf{n} \sim \mathcal{N}(\mathbf{0}, \sigma^2\mathbf{I}),$$

توابع `estimate_amplitude_mle` و `run_monte_carlo` را کامل کنید. دامنه، پارامتری حقیقی و نامقید است. MLE را با روش آماده peak-based estimation مقایسه کنید. با آزمایش Monte Carlo، بایاس، واریانس و MSE را بررسی کرده و واریانس تجربی را با مقدار نظری و CRLB مقایسه کنید. اثر تغییر شدت نویز را با آزمایش آماده بررسی کنید.

1.2 نویز همبسته و baseline نامعلوم

مدل این بخش با نویز گاوسی برابر است با

$$\mathbf{y} = a\mathbf{s} + b\mathbf{1} + \mathbf{n} = \mathbf{A}\boldsymbol{\theta} + \mathbf{n}, \qquad [\boldsymbol{\Sigma}]_{ij} = \sigma^2\rho^{|i-j|}, \quad 0 \le \rho < 1.$$

توابع `gaussian_linear_loglikelihood` و `gaussian_linear_mle` را کامل کنید. نادیده‌گرفتن baseline، روش OLS و روش GLS را با نتایج عددی و نمودارهای آماده مقایسه کنید. کوواریانس تجربی برآورد را با معکوس اطلاعات فیشر و تغییر واریانس هر پارامتر را با تغییر همبستگی نویز بررسی کنید.

1.3 برآورد بیزی و ناسازگاری prior

با prior $\boldsymbol{\theta} \sim \mathcal{N}(\boldsymbol{\mu}_0, \mathbf{P}_0)$، توابع `gaussian_linear_posterior` و `simulate_prior_predictive` را کامل کنید. اثر میانگین و شدت prior مفروض را در دو حالت بررسی کنید: پارامتر واقعی ثابت، و پارامترهای تصادفی حاصل از prior واقعی (prior predictive). جمعیت واقعی در مقایسه prior های مفروض ثابت بماند.

MSE کل، trace کوواریانس posterior و coverage نواحی معتبر مشترک ۹۵ درصد را بررسی کنید. سپس در مدل دو الگوی یکسان، $\mathbf{y} = (\theta_1 + \theta_2)\mathbf{s} + \mathbf{n}$، عدم قطعیت جهت‌های مجموع و تفاضل را مقایسه کنید.

1.4 یک posterior، معیارهای تصمیم متفاوت

در مدل $a \in \{0, A\}$ با $P(a = A) = \pi$، baseline معلوم و حذف شده است. توابع `binary_amplitude_posterior` و `binary_amplitude_actions` را کامل کنید. از یک posterior، تصمیم MAP، برآورد MMSE و تصمیم کمینه‌هزینه را بسازید. با آزمایش‌های آماده، خطای طبقه‌بندی، خطای مربعی، هزینه تصمیم و زیان مورد انتظار posterior را مقایسه کنید.

2 یادگیری از داده‌های آکوستیکی واقعی

با داده Airfoil Self-Noise از UCI، ابتدا تراز فشار صوت را پیش‌بینی کرده و سپس یک مسئله تشخیص high-response پیاده‌سازی کنید. پنج ورودی شامل فرکانس، زاویه حمله، طول وتر، سرعت جریان و ضخامت جابه‌جایی لایه مرزی هستند. هدف، scaled sound pressure level در واحد دسی‌بل است.

برای LASSO می‌توانید از `sklearn.linear_model.Lasso` استفاده کنید.

2.1 بررسی داده و تقسیم‌بندی

کیفیت داده و واحد متغیرها را بررسی کنید. گروه را با یکسان بودن چهار ورودی غیرفرکانسی تعریف کنید و همه اندازه‌گیری‌های یک گروه را در یک بخش نگه دارید. تقسیم train/validation/test ۶۰/۲۰/۲۰ درصدی از گروه‌ها بسازید و نبود اشتراک سطری و گروهی را کنترل کنید.

تعداد سطرها و گروه‌ها را گزارش کرده و نمودار فرکانس در برابر شناسه گروه و منحنی پاسخ سه نمونه از داده آموزش را رسم کنید.

2.2 نمایش ویژگی‌ها و هندسه مسئله

سه نمایش `raw`، `log` و `log_poly2` را بسازید: نسبت‌های مرجع در تبدیل لگاریتمی عبارت‌اند از:

$$\log_{10}\frac{f}{1000\,\mathrm{Hz}},\quad \log_{10}\frac{c}{0.1\,\mathrm{m}},\quad \log_{10}\frac{U}{50\,\mathrm{m/s}},\quad \log_{10}\frac{\delta}{0.001\,\mathrm{m}}.$$

ویژگی‌ها را پس از ساخت هر نمایش استاندارد کنید (هدف در واحد دسی‌بل بماند). یک شکل دوپنلی از همبستگی ویژگی‌های `log` و طیف مقادیراستانداردشده ارائه دهید. سه fold گروهی برای cross-validation فقط در آموزش بسازید. پیش‌پردازش هر fold باید از داده برازش همان fold آموخته شود.

2.3 رگرسیون و regularization

برای هر نمایش، OLS، Ridge و LASSO را مقایسه کنید. توابع هدف دو روش آخر عبارت‌اند از

$$\frac{\|\mathbf{y}-b\mathbf{1}-\mathbf{Z}\mathbf{w}\|_2^2}{2n}+\frac{\lambda}{2}\|\mathbf{w}\|_2^2, \qquad \frac{\|\mathbf{y}-b\mathbf{1}-\mathbf{Z}\mathbf{w}\|_2^2}{2n}+\lambda\|\mathbf{w}\|_1.$$

شبکه penalty را به‌صورت زیر بگیرید:

$$\text{Ridge} : \lambda \in \{10^{-5+0.5j} : j=0,\dots,12\},$$
$$\text{LASSO} : \lambda \in \{10^{-3+j/3} : j=0,\dots,12\}.$$

برای هر ترکیب نمایش و روش، penalty را با RMSE تجمیعی پیش‌بینی‌های out-of-fold انتخاب کنید. ۹ مدل حاصل را روی validation با RMSE، MAE و تعداد ضرایب غیرصفر مقایسه کرده و مدل نهایی را با کمترین RMSE انتخاب کنید. خط مبنای میانگین آموزش را نیز گزارش کنید.

برای `log_poly2`، منحنی خطای برازش و CV برحسب penalty را با خطوط مبنا رسم کنید. برای مدل منتخب، نمودار پیش‌بینی در برابر مشاهده و باقیمانده برحسب فرکانس را روی validation ارائه دهید.

2.4 از پیش‌بینی تا تشخیص

نمونه‌های با هدف برابر یا بالاتر از صدک ۷۵ اهداف آموزش را کلاس ۱ و بقیه را کلاس ۰ بگیرید. با نمایش `log`، کلاسفایر گاوسی با کوواریانس مشترک و logistic regression پیاده‌سازی کنید. امتیاز گاوسی و گرادیان تابع هدف لجستیک را استخراج کنید.

برای گاوسی از $\widehat{\Sigma}=(1-\rho)S+\rho\,\mathrm{tr}(S)I/p$ با کوواریانس درون‌کلاسی S و مخرج n استفاده کنید. تابع هدف لجستیک، میانگین log loss به‌علاوه $\lambda\|\mathbf{w}\|_2^2/2$ است. پارامترها را با CV گروهی و log loss تجمیعی انتخاب کنید:

$$\rho \in \{0.001, 0.01, 0.1, 0.5, 1\}, \qquad \lambda \in \{10^{-4}, 10^{-3}, 10^{-2}, 10^{-1}, 1, 10\}.$$

پیش‌بینی رگرسیون منتخب را نیز سومین امتیاز تشخیص بگیرید. روی validation، آستانه‌های با بیشترین نرخ تشخیص و نرخ هشدار کاذب حداکثر ۰٫۱۰ را انتخاب کنید. معیارهای تشخیص، ماتریس درهم‌ریختگی، ROC-AUC و AP را گزارش کرده و منحنی‌های ROC و precision-recall را رسم کنید. روش نهایی با نرخ تشخیص بیشتر و در تساوی با AP بیشتر انتخاب شود.

2.5 ارزیابی نهایی و تفسیر

مدل‌ها و آستانه‌های ثابت را روی test ارزیابی کنید. برای رگرسیون منتخب و خط مبنای میانگین آموزش، RMSE/MAE و برای سه روش تشخیص، معیارهای بخش قبل را گزارش کنید

نرخ هشدار کاذب validation/test را مقایسه کرده و با ثابت نگه‌داشتن نرخ‌های شرطی آزمون، precision را برای $\pi \in [0.01, 0.8]$ رسم کنید.

3 تشخیص مدولاسیون از بسته‌های سیگنال نویزی

گیرنده، بسته‌های کوتاه BPSK، QPSK و 16-QAM را با بهره و فاز نامعلوم و نویز جمع‌شونده مشاهده می‌کند. با مولد و استخراج‌کننده ویژگی آماده، دو کلاسیفایر LDA و QDA را پیاده‌سازی کرده و عملکرد و کیفیت احتمال‌های آن‌ها را مقایسه کنید.

3.1 داده‌ها و ویژگی‌ها

دو مجموعه مستقل آموزش و آزمون، هریک شامل ۶۰۰ بسته، با تنظیمات آماده و بازه SNR برابر ۵ تا ۱۵ دسی‌بل بسازید. ابعاد، متناهی‌بودن مقادیر، معتبر بودن برچسب‌ها و فراوانی کلاس‌های آموزش را بررسی کنید. SNR اطلاعات جانبی است و ورودی مدل نیست.

یک شکل شامل نمودارهای I/Q یک بسته آموزشی از هر کلاس و پراکندگی دوبعدی ویژگی‌های آموزش رسم کنید. رنگ کلاس‌ها ثابت و مقیاس محورهای I/Q برابر باشد.

3.2 یادگیری و مقایسه کلاسیفایرهای گوسی

امتیاز کلاس و احتمال posterior نرمال‌شده LDA/QDA را استخراج و پیاده‌سازی کنید.

برای LDA، کوواریانس درون‌کلاسی مشترک را با مخرج n و برای QDA، کوواریانس هر کلاس را با مخرج n_k برآورد کنید. به کوواریانس مربوط، منظم‌سازی زیر را اعمال کنید:

$$\widehat{\Sigma} = (1-\rho)S + \rho\frac{\mathrm{tr}(S)}{d}I, \qquad \rho = 0.01.$$

برای محاسبات پایدار از تجزیه چولسکی و logsumexp استفاده کنید.

برای هر دو مدل، training log loss و همچنین accuracy، log loss و Brier score روی test را گزارش کنید. مدل‌ها و تنظیمات آن‌ها باید پیش از مشاهده نتایج test ثابت باشند. قرارداد امتیاز Brier برابر است با

$$\frac{1}{n}\sum_{i}\sum_{k}\left(\widehat{p}_{ik} - \mathbf{1}\{y_i = k\}\right)^2.$$

یک شکل سه‌پنلی شامل نواحی تصمیم LDA و QDA با مشاهدات تست، و منحنی‌های قابلیت اعتماد دو مدل ارائه دهید.

4 کشف حالت‌های پنهان کارکرد ماشین

یک سیستم پایش ارتعاش، برای هر بازه اندازه‌گیری دو ویژگی ثبت می‌کند: log band power در باند فرکانسی پایین و بالا، برحسب دسی‌بل. هدف، شناسایی حالت‌های مختلف کارکرد ماشین با GMM و الگوریتم EM است.

در داده‌های شبیه‌سازی‌شده، اندازه‌گیری‌های مربوط به هر حالت از یک توزیع گوسی چندمتغیره تولید می‌شوند. این فرض، مدل ساده‌شده‌ای از اندازه‌گیری‌های واقعی است.

کد تولید داده، محاسبات عددی، initialization، حلقه EM و اجرای مدل با چند initialization به شما داده شده‌اند.

4.1 پیاده‌سازی و بررسی EM

روابط responsibility و فرمول‌های به‌روزرسانی وزن‌ها، میانگین‌ها و ماتریس‌های کوواریانس را به دست آورید. توابع `q4_e_step` و `q4_m_step` را تکمیل کنید.

می‌توانید از توابع آماده برای محاسبه Gaussian log density و اعمال حداقل مقدار ویژه کوواریانس استفاده کنید. این حد در فضای استانداردشده برابر 10^{-3} باشد.

کد آماده بررسی یک تکرار E-step و M-step را برای داده‌های

$$x = \{-2, -1, 0, 3, 4\}$$

با دو مؤلفه دارای وزن برابر، میانگین‌های -1 و 3 و واریانس‌های یک اجرا کنید. پارامترهای جدید و total log likelihood قبل و بعد از به‌روزرسانی را گزارش کنید. فقط برای این مثال کوچک، حداقل واریانس را صفر بگیرید.

4.2 آموزش مدل و انتخاب تعداد مؤلفه‌ها

از مجموعه‌های آماده train و test، هریک شامل ۶۰۰ مشاهده، استفاده کنید.

برای هر $K = 1, \dots, 5$، مدل را با سه initialization اجرا کنید. وضعیت convergence اجراها را گزارش دهید. برای هر K، از میان اجراهای همگرا، مدلی را نگه دارید که بیشترین training log likelihood را دارد. اگر برای یک K هیچ اجرایی همگرا نشد، قبل از ادامه، علت را بررسی کنید.

برای هر مدل نگه‌داشته‌شده، میانگین log density روی train و test در فضای استانداردشده، تعداد پارامترها و training BIC را گزارش کنید:

$$q_K = (K-1) + Kd + K\frac{d(d+1)}{2}, \qquad \mathrm{BIC} = -2\ell_{\mathrm{train}} + q_K \log n, \qquad d = 2.$$

در این رابطه، ℓ_{train} برابر total training log likelihood است.

مدل با کمترین training BIC را انتخاب کنید. این انتخاب باید قبل از بررسی برچسب‌ها انجام شود.

4.3 بررسی نتایج

پس از انتخاب مدل، با استفاده از برچسب‌های واقعی test، مقدار ARI و یک جدول مقایسه حالت واقعی با مؤلفه تشخیص‌داده‌شده ارائه کنید. بر اساس این نتایج، مدل انتخاب‌شده را تغییر ندهید.

برای هر مشاهده test، بیشترین responsibility را پیدا کنید. سپس مشاهده‌ای را انتخاب کنید که این مقدار برای آن از همه کمتر است. دو ویژگی اولیه و بردار responsibility آن را گزارش کنید.

یک شکل دوپنلی رسم کنید:

۱. تغییرات training log likelihood طی اجراهای مختلف برای K انتخاب‌شده.

۲. داده‌های train با مؤلفه اختصاص‌یافته، همراه با 95% probability contours مؤلفه‌ها در مقیاس اولیه ویژگی‌ها.