

دانشگاه صنعتی امیرکبیر ــ دانشکده مهندسی برق

یادگیری ماشین برای پردازش سیگنال

تمرین دوم- ددلاین: پنجشنبه ۱۴۰۵/۰۸/۲۸

Instructions and Submission Guidelines

این تمرین شامل چهار مسئله است. ابتدا بخش صفر نوت‌بوک را اجرا کنید. توابع مشخص‌شده با TODO-FUNCTION را تکمیل کرده و آزمایش‌های TODO-EXPERIMENT را مطابق صورت سؤال پیاده‌سازی کنید. روابط، نمودارها، جدول‌ها و تحلیل‌ها باید در همان نوت‌بوک ارائه شوند و گزارش جداگانه لازم نیست. قبل از تحویل، با Kernel → Restart & Run All از اجرای ترتیبی و بازتولیدپذیری نتایج مطمئن شوید.

استفاده از pandas، Matplotlib، SciPy، NumPy، ابزارهای تقسیم داده و محاسبه معیارها و LogisticRegression برای مسئله طبقه‌بندی مجاز است. استفاده از برازشگر آماده برای OMP، PCA و ISTA مجاز نیست. Soft Thresholding آماده در بخش Setup صرفاً یک تابع کمکی است؛ گام‌های ISTA باید پیاده‌سازی شوند. تمام مراحل یادگیری نمایش و انتخاب پارامتر باید بدون استفاده از داده آزمون نهایی انجام شوند. مقادیر عددی و قرارداد ورودی/خروجی توابع مطابق نوت‌بوک است.

1. Question 1 - Recovering Structure from Noisy Multi-Sensor Measurement (25 points)

یک سامانه هشت‌حسگری، فرایندی را ثبت می‌کند که تنها دو منبع نهفته مستقل تغییرات اصلی آن را ایجاد می‌کنند. سیگنال پاک در یک زیرفضای دوبعدی قرار دارد، اما هر حسگر با نویز گاوسی مستقل آلوده می‌شود. هدف، تخمین زیرفضای سیگنال از مشاهدات، بازسازی با رتبه محدود و بررسی پایداری جهت‌های برآوردشده است. مدل داده به‌صورت زیر است:

$$Y = Z\,B^T + \sigma\,E, \quad B \in \mathbb{R}^{8x2}, \quad B^TB = I_2, \quad E_{ij} \sim N(0,1)$$

1.1. Regularized PCA (6 points)

با داده‌های هشت‌حسگریِ معرفی‌شده، ماتریس Covariance مرکزشده را محاسبه کنید. Regularized PCA را با $C\gamma=(1-\gamma)C+\gamma\ \mathrm{diag}(\mathrm{diag}(C))$ و $\gamma\in\{0,0.1,0.3\}$ پیاده‌سازی کنید. زیرفضای دوبعدی حاصل را از نظر Principal Angle و خطای بازسازی مقایسه کرده و توضیح دهید اثر Regularization چگونه به ساختار Covariance وابسته است.

(الف: استخراج و پیاده‌سازی: ۳ نمره، ب: مقایسه عددی: ۲ نمره، ج: تحلیل: ۱ نمره)

1.2. Low-Rank Reconstruction and Denoising (6 points)

برای رتبه‌های ۱ تا ۸، خطای بازسازی مشاهدات نویزی، خطای بازیابی سیگنال پاک و انرژی مقادیر منفرد حذف‌شده را رسم کنید. توضیح دهید چرا رتبه مناسب برای کاهش نویز ممکن است با رتبه مناسب برای برازش داده مشاهده‌شده متفاوت باشد.

(الف: محاسبه و رسم سه معیار برای رتبه‌های ۱ تا ۸: ۳ نمره، ب: مقایسه و تعیین رتبه مناسب: ۱ نمره، ج: تفسیر تفاوت برازش مشاهدات و Denoising: ۲ نمره.)

1.3. Subspace Stability under Monte Carlo Simulation (8 points)

برای $N=\{30,80,250\}$ و $\sigma=\{0.2,0.8,1.5\}$، در هر ترکیب ۲۵ اجرای مستقل انجام دهید. زیرفضای واقعی را ثابت نگه دارید و بزرگ‌ترین Principal Angle بین زیرفضای واقعی و برآوردشده را محاسبه کنید. میانگین و انحراف معیار و یک Heatmap ارائه دهید. نقش اندازه نمونه، نویز و فاصله مقادیر ویژه را تحلیل کنید.

(الف: طراحی و اجرای Monte Carlo با تنظیمات خواسته‌شده: ۳ نمره، ب: محاسبه Principal Angle و آمار خلاصه: ۲ نمره، ج: Heatmap و گزارش نتایج: ۱ نمره،؛ د: تحلیل اثر N، نویز و Eigenvalue Gap: ۲ نمره.)

1.4. Representation Assumptions and Preprocessing (5 points)

رابطه خطای تقریب بهینه در قضیه Eckart–Young–Mirsky را توضیح دهید. نتیجه PCA را در دو حالت حذف Centering و ضرب یک ویژگی در عدد ۱۰ بررسی کنید. تفاوت نتایج را با توجه به واحد حسگرها و مفروضات مدل تفسیر کنید.

(الف: توضیح رابطه Eckart–Young–Mirsky: ۲ نمره، ب: اجرای دو آزمایش Centering و Scaling: ۲ نمره، ج: تفسیر نتایج: ۱ نمره.)

Helpful Resources:

- Introduction to Applied Linear Algebra
- SciPy Subspace Angles

2. Question 2 — Learning Low-Dimensional Representations and Evaluating Retained Information (25 points)

کاهش بُعد می‌تواند خطای بازسازی را کاهش دهد، اما تضمین نمی‌کند اطلاعات لازم برای یک وظیفه تشخیصی حفظ شوند. این مسئله در دو مجموعه جدا بررسی می‌شود: تصاویر چهره بدون برچسب هویت برای Eigenfaces و تصاویر برچسب‌دار ارقام دست‌نویس برای طبقه‌بندی. استفاده از تصاویر چهره برای ادعای ارزیابی شناسایی هویت مجاز نیست.

2.1. Eigenfaces and Test-Set Reconstruction (6 points)

تصاویر چهره را با random seed ثابت به نسبت ۲۵/۷۵ تقسیم کنید. Mean Face و پنج Eigenface اول را فقط از داده آموزش استخراج کنید. تصاویر آزمون را با $k=\{1,3,5,10,20,40\}$ بازسازی کرده و خطای MSE پیکسلی آزمون و واریانس توضیح‌داده‌شده تجمعی داده آموزش را گزارش کنید.

(الف: تقسیم داده و برازش Mean Face/Eigenfaces فقط روی Train: ۲ نمره، ب: بازسازی Test برای همه مقادیر k: ۲ نمره، ج: گزارش و تحلیل MSE و Explained Variance: ۲ نمره.)

2.2. Dimensionality Reduction and Digit Classification (10 points)

داده ارقام را با حفظ نسبت کلاس‌ها به سه مجموعه ۲۰/۲۰/۶۰ تقسیم کنید. PCA را فقط روی آموزش برازش داده و برای $k=\{2,5,10,20,40\}$ یک LogisticRegression با C=۱ و max_iter=۲۰۰۰ آموزش دهید. k را با دقت اعتبارسنجی و در تساوی با کمترین رتبه انتخاب کنید. روش منتخب را فقط یک‌بار روی آزمون ارزیابی کرده و با طبقه‌بند روی پیکسل‌های خام مقایسه کنید؛ ماتریس درهم‌ریختگی و ارتباط خطای بازسازی با دقت طبقه‌بندی را تحلیل کنید.

(الف: تقسیم Stratified و پیشگیری از Data Leakage: ۲ نمره، ب: آموزش PCA و طبقه‌بند برای همه رتبه‌ها: ۳ نمره، ج: انتخاب k بر اساس Validation: ۲ نمره، د: مقایسه نهایی با Raw Pixels روی Test: ۲ نمره، هـ: Confusion Matrix و تحلیل رابطه بازسازی و Accuracy: ۱ نمره.)

2.3. A Counterexample for PCA (5 points)

داده دوبعدی تولید کنید که یک ویژگی با واریانس زیاد مزاحم و ویژگی دیگر با واریانس کم تعیین‌کننده برچسب باشد؛ از پارامترهای مشخص‌شده در نوت‌بوک استفاده کنید. عملکرد طبقه‌بند مبتنی بر PC1 را با ویژگی اطلاع‌رسان روی داده آزمون مستقل مقایسه کنید و توضیح دهید چرا بیشینه‌سازی واریانس تضمین‌کننده دقت طبقه‌بندی نیست.

(الف: ساخت داده با فرضیات خواسته‌شده: ۲ نمره، ب: مقایسه طبقه‌بندی در Test مستقل: ۲ نمره، ج: توضیح شکست PCA برای Task: ۱ نمره.)

2.4. Regularized Whitening (4 points)

رابطه Whitening مبتنی بر PCA را استخراج کرده و اثر دو مقدار ε بر قطر کوواریانس خروجی را بسنجید. نقش مقادیر ویژه کوچک در تقویت نویز را توضیح داده و تفاوت نامرتبط‌بودن و استقلال آماری را روشن کنید.

(الف: استخراج رابطه Whitening: ۱ نمره، ب: آزمایش دو ε و بررسی قطر Covariance: ۲ نمره، ج: تحلیل نویز و تفاوت Decorrelation/Independence: ۱ نمره.)

Helpful Resources:

- scikit-image Dataset Reference
- scikit-learn Digits Dataset
- scikit-learn Train/Test Split

3. Question 3 — Sparse Recovery, OMP, ISTA and Compressed Sensing (35 points)

در یک سیستم بازسازی، سیگنال از تعداد کمی الگوی پایه در یک Dictionary بیش‌کامل تشکیل شده است. با داشتن سیگنال نویزی و Dictionary معلوم، باید هم مکان اتم‌های فعال و هم دامنه ضرایب آن‌ها برآورد شوند. مدل داده به‌صورت زیر در نظر گرفته می‌شود:

$$y = D\,\alpha + n, \quad D \in \mathbb{R}^{64\times128}, \quad \|\alpha\|_0 = 4, \quad \|d_j\|_2 = 1$$

3.1. Orthogonal Matching Pursuit Implementation (9 points)

تابع omp را از پایه پیاده‌سازی کنید: انتخاب اتم استفاده‌نشده با بیشترین قدرمطلق همبستگی با Residual، افزودن اتم، بازبرازش همه ضرایب با Least Squares، ثبت تاریخچه نرم Residual و کنترل توقف. برای یک Dictionary با ۶۴ سطر و ۱۲۸ ستون و چهار ضریب فعال، ترتیب انتخاب اتم‌ها و کاهش Residual را نمایش دهید.

(الف: انتخاب Atom و مدیریت Support: ۳ نمره، ب: Least Squares، به‌روزرسانی Residual و معیار توقف: ۳ نمره، ج: ذخیره History و صحت‌سنجی خروجی: ۲ نمره، د: نمایش ترتیب انتخاب و تحلیل Residual: ۱ نمره.)

3.2. OMP versus ISTA (7 points)

ISTA را با گام Gradient و Soft Thresholding برای $\min_\alpha \tfrac{1}{2}\|y-D\alpha\|_2^2+\lambda\|\alpha\|_1$ پیاده‌سازی کنید و نمودار Objective را گزارش دهید. برای مقایسه نهایی از $n=96, m=48, k=4$ و $\mathrm{SNR}=\{0,10,20\}$ dB استفاده کنید. برای هر سطح SNR حداقل ۳۰ Paired Trials مستقل با اندازه‌گیری‌های یکسان برای OMP و ISTA اجرا کنید. λ را روی مجموعه Validation مستقل انتخاب و در Test ثابت نگه دارید. برای هر روش mean و standard deviation مربوط به NMSE ضرایب، Support Recovery، Exact Support، Precision/Recall و runtime را گزارش و دلایل شکست را تحلیل کنید.

(الف: پیاده‌سازی ISTA و نمودار Objective: ۳ نمره، ب: طراحی Paired Trials و انتخاب λ روی Validation مستقل: ۲ نمره، ج: گزارش آماری معیارها و تحلیل نتایج: ۲ نمره.)

3.3. Coherence Stress Test (5 points)

یک Dictionary معمولی و نمونه‌ای با دو اتم تقریباً مشابه بسازید. Coherence هر دو را اندازه بگیرید و با ثابت‌نگه‌داشتن تعداد اتم، تنکی و SNR، در ۵۰ آزمایش مستقل نرخ بازیابی دقیق Support را مقایسه کنید. توضیح دهید شباهت اتم‌ها چگونه موجب ابهام می‌شود.

(الف: ساخت دو Dictionary با شرایط کنترل‌شده: ۲ نمره، ب: محاسبه Coherence: ۱ نمره، ج: مقایسه در ۵۰ Trial مستقل: ۱ نمره، د: تفسیر ابهام Support: ۱ نمره.)

3.4. Underdetermined Sensing Model (5 points)

تابع make_cs_problem را با ستون‌های نرمال‌شده گاوسی، دقیقاً k ضریب غیرصفر، random seed ثابت و نویز با SNR مشخص تکمیل کنید. ابعاد، Support و نرم ستون‌ها را کنترل کرده و قرارداد نمایش x را بیان کنید.

(الف: پیاده‌سازی make_cs_problem و تولید داده با SNR مشخص: ۳ نمره، ب: کنترل ابعاد، Sparsity و نرمال‌سازی: ۱ نمره، ج: تشریح قرارداد نمایش و Random Seed: ۱ نمره.)

3.5. Empirical Recovery Boundary (9 points)

با $m=\{16,24,32,48,64\}$ ،$n=96$ و $k=\{2,4,6,8,12\}$، در هر ترکیب حداقل ۳۰ اجرای مستقل و بدون نویز انجام دهید. در این آزمایش کنترل‌شده، OMP از k واقعی به‌عنوان بودجه توقف استفاده می‌کند. دو Heatmap برای موفقیت $NMSE<10^{-3}$ و بازیابی دقیق Support رسم کنید. عدم‌قطعیت نرخ موفقیت را با خطای استاندارد دوجمله‌ای یا بازه اطمینان گزارش کنید و روندها را توضیح دهید.

(الف: اجرای Grid با ۳۰ Trial مستقل در هر حالت: ۳ نمره، ب: رسم دو Heatmap و محاسبه نرخ موفقیت: ۳ نمره، ج: برآورد عدم‌قطعیت آماری: ۲ نمره، د: تفسیر مرز بازیابی: ۱ نمره.)

Helpful Resources:

- Introduction to Applied Linear Algebra
- SciPy Linear Algebra Reference

4. Question 4 — Missing-Sample Recovery after Burst Loss (15 points)

در بازسازی سیگنال با اندازه‌گیری‌های ناقص، یک Missing Signal Block ناشی از Burst Loss را با حذف تصادفی نمونه‌ها مقایسه کنید. مدل مشاهده همان $y=Mx+n$ و فرض تنکی در پایه DCT است.

$$y = M\,x + n, \quad x = D\,\alpha, \quad \|\alpha\|_0 = 5$$

4.1. Random Missing Samples versus Burst Loss (15 points)

یک سیگنال ۱۲۸نمونه‌ای با پنج ضریب غیرصفر در پایه متعامد DCT تولید کنید. ۴۰٪ نمونه‌های زمانی را یک‌بار به‌صورت Random Missing Samples و بار دیگر در قالب یک Missing Signal Block پیوسته (Burst Loss) حذف کنید. با OMP و Effective Sensing Matrix بازسازی انجام دهید. خطای نمونه‌های گمشده و NMSE را با Zero-Fill مقایسه کنید و تفاوت الگوهای حذف را توضیح دهید.

(الف: تولید سیگنال و دو Mask با نرخ حذف یکسان: ۳ نمره، ب: بازسازی با Effective Sensing Matrix و OMP: ۵ نمره، ج: مقایسه Missing-Sample MSE و NMSE با Zero-Fill: ۳ نمره، د: تحلیل اثر Random Missing Samples در برابر Burst Loss: ۴ نمره.)

Helpful Resources:

- SciPy DCT Documentation
- SciPy IDCT Documentation

Bonus Problems (15 extra points)

Bonus A — Non-negative Matrix Factorization (NMF) (+10 points)

برای یک ماتریس نامنفی V، مدل $V \approx WH$ را با $W,H \geq 0$ در نظر بگیرید.

(الف، ۳ نمره) تابع هدف Frobenius و نقش عامل‌های نامنفی را توضیح دهید.

(ب، ۴ نمره) Multiplicative Updates را با دو initialization مستقل پیاده‌سازی کرده و نمودار objective را رسم کنید.

(ج، ۳ نمره) خطای بازسازی، تغییر rank و محدودیت‌های تفسیر عامل‌ها را بررسی کنید.

Helpful Resources:

- Introduction to Applied Linear Algebra
- Algorithms for Non-negative Matrix Factorization

Bonus B — Canonical Correlation Analysis (CCA) (+5 points)

(الف، ۲ نمره) مسئله CCA را برای دو نمای سنسوری با یک عامل نهفته مشترک صورت‌بندی کنید.

(ب، ۲ نمره) Regularized CCA را با Whitening و SVD پیاده‌سازی کنید.

(ج، ۱ نمره) Canonical Correlation را تحت سه سطح نویز گزارش دهید.

Helpful Resources:

- Introduction to Applied Linear Algebra
- Sklearn cross decomposition CCA

Final Instructions and Submission

تمام پاسخ‌ها و تحلیل‌ها در نوت‌بوک دانشجویی تکمیل شوند. هر نمودار باید محور، عنوان و تحلیل داشته باشد. تعریف خطا، قرارداد random seed، SNRهای تصادفی، آستانه بازیابی Support و اندازه مجموعه‌ها را ذکر کنید. پارامترهای انتخاب‌شده پس از مشاهده نتایج آزمون نباید تغییر کنند. فایل را پس از اجرای مجدد تمام سلول‌ها تحویل دهید.